

Università degli studi di Milano

Corso di Laurea Magistrale in Sicurezza Informatica

Sicurezza nelle Architetture Data Intensive

Titolo del progetto

Docente: Ernesto Damiani

Anno: I° Anno

Trimestre: III° Trimestre

Anno Accademico: 2025/2026

Componenti del gruppo:

Giuseppe Corasaniti - Matricola 84237A

Giuseppe Favata - Matricola 84231A

Matteo Toso - Matricola 85540A

Indice

1	Architettura del sistema	2
1.1	Ambito del sistema e integrazione con B4	2
1.2	Pipeline di elaborazione e decisione clinica	3
1.2.1	Stage 1 - Classificazione dell'urgenza con EfficientNet-B4	3
1.2.2	Stage 2 - Descrizione clinica con Qwen2-VL	3
1.2.3	Stage 3 - Recupero di casi clinici simili	4
1.2.4	Stage 4 - Sintesi clinica con BioMistral	4
1.2.5	Adaptation layer e assegnazione della priorità	4
1.3	Componenti persistenti, modelli e dipendenze esterne	5
1.3.1	Dataset e persistenza dei dati	5
1.3.2	Modelli e checkpoint	6
1.3.3	Ambiente di esecuzione e servizi esterni	6
1.4	Aggiornamento e validazione del sistema	6
1.4.1	Validazione clinica e raccolta del feedback	6
1.4.2	Evoluzione dei prompt	7
1.4.3	Retraining del classificatore EfficientNet-B4	7
1.4.4	Validazione tecnica e gestione delle versioni	7
2	Identificazione degli asset	9
2.1	Dati clinici e input	9
2.2	Inferenze e risultati della pipeline	10
2.3	Dataset e persistenza	10
2.4	Feedback e aggiornamento	11
2.5	Modelli e artefatti AI	12
2.6	Logica decisionale	13
2.7	Servizi applicativi e configurazione	14
3	Failure Mode and Effects Analysis	15
3.1	A01 – Immagine dermatologica	15
3.1.1	Funzioni e prerequisiti	15
3.1.2	Failure mode	15
3.2	A09 – Dataset clinico RAG	16
3.2.1	Funzioni e prerequisiti	16
3.2.2	Failure mode	17
3.3	A16 – Modello EfficientNet-B4	18
3.3.1	Funzioni e prerequisiti	18
3.3.2	Failure mode	18

1. Architettura del sistema

DermaTriage è un sistema di triage dermatologico assistito da intelligenza artificiale, sviluppato nell'ambito del progetto AI vs Cancer. Il sistema elabora immagini di lesioni cutanee inviate dai pazienti insieme a informazioni cliniche e demografiche, con l'obiettivo di stimare il livello di urgenza del caso e assegnare una priorità clinica compresa tra P1 e P4.

DermaTriage è integrato con la piattaforma B4 (Social Things), che rappresenta il punto di interazione con il paziente e mette a disposizione le API utilizzate per lo scambio dei dati relativi ai consulti, ai documenti caricati, ai risultati diagnostici e alle validazioni mediche. L'elaborazione diagnostica viene invece eseguita dal servizio DermaTriage, che espone un'applicazione FastAPI e implementa una pipeline di intelligenza artificiale composta da quattro stadi, seguita da un adaptation layer responsabile della conversione del risultato nella scala clinica P1-P4.

1.1. Ambito del sistema e integrazione con B4

L'interazione con il paziente avviene attraverso la piattaforma B4, che raccoglie le informazioni necessarie per avviare il processo di triage. Nel flusso principale vengono acquisiti un'immagine della lesione cutanea, l'età del paziente, il sesso e la localizzazione anatomica della lesione. A questi dati possono aggiungersi informazioni relative alla sintomatologia, tra cui prurito, sanguinamento, crescita della lesione, cambiamenti morfologici e dolore.

Una volta raccolti i dati, DermaTriage accede alle informazioni associate alla richiesta attraverso le API messe a disposizione da B4. Il servizio può recuperare i consulti disponibili, individuare i documenti associati e scaricare l'immagine dermatologica necessaria all'elaborazione. Al termine della pipeline diagnostica, il risultato viene restituito a B4 e associato alla relativa richiesta di triage. La successiva validazione da parte del personale medico permette di ottenere un riscontro sull'esito prodotto dal sistema. Tali informazioni possono essere recuperate da DermaTriage e alimentare i meccanismi di aggiornamento del sistema, che comprendono l'evoluzione dei prompt e il retraining del classificatore EfficientNet-B4.

La comunicazione tra DermaTriage e B4 avviene tramite API REST protette da autenticazione. L'accesso ai servizi B4 utilizza un Bearer JWT ottenuto tramite l'endpoint `/api/v1/auth/token`; la gestione del token è affidata al componente `B4Auth`, che ne esegue il rinnovo automatico alla scadenza. I parametri necessari all'integrazione, tra cui credenziali, API key e indirizzo del servizio B4, sono configurati mediante variabili d'ambiente dedicate.

Il flusso integrato viene avviato attraverso l'endpoint `POST /diagnose`, al quale viene fornito un `consulto_id` come riferimento alla richiesta da elaborare. L'accesso a questo

endpoint richiede l'header `X-API-Key`, utilizzato anche per le funzionalità amministrative relative alla validazione delle diagnosi, alla gestione dei prompt e al retraining dei modelli.

Accanto al percorso integrato con B4, DermaTriage espone anche `POST /analyze`, che permette di avviare direttamente la pipeline fornendo un'immagine JPEG o PNG insieme a età, sesso e localizzazione. Questo secondo percorso consente quindi di utilizzare il motore diagnostico anche senza partire da una richiesta già presente sulla piattaforma B4.

Dal punto di vista architetturale, B4 e DermaTriage mantengono ruoli distinti. B4 gestisce l'interazione iniziale con il paziente e rende disponibili i dati necessari al processo di triage, mentre DermaTriage esegue l'elaborazione diagnostica e gestisce i meccanismi di aggiornamento dei modelli. L'integrazione tra i due sistemi è quindi bidirezionale e accompagna il caso clinico dalla fase di acquisizione fino alla restituzione e alla successiva validazione del risultato.

1.2. Pipeline di elaborazione e decisione clinica

L'elaborazione interna di DermaTriage si articola in quattro stadi che contribuiscono alla costruzione del risultato finale. L'architettura combina un classificatore visuale, un modello vision-language, un sistema di retrieval basato su casi clinici e un modello linguistico specializzato in ambito medico. Il risultato ottenuto viene successivamente trasformato nella priorità clinica utilizzata dal sistema.

1.2.1. Stage 1 - Classificazione dell'urgenza con EfficientNet-B4

Il primo stadio esegue una classificazione dell'immagine della lesione attraverso EfficientNet-B4, un modello convoluzionale sottoposto a fine-tuning per distinguere tre livelli di urgenza denominati `HIGH`, `MEDIUM` e `LOW`. L'immagine viene elaborata come input RGB di dimensione 380×380 pixel e il modello restituisce, oltre alla classe prevista, un valore di confidenza e le probabilità associate alle tre classi.

Per aumentare la sensibilità verso i casi considerati più urgenti, la classificazione `HIGH` utilizza una soglia operativa pari a 0.25. Questa prima valutazione non determina direttamente la priorità finale P1-P4, ma costituisce una delle informazioni utilizzate nelle fasi successive della pipeline.

1.2.2. Stage 2 - Descrizione clinica con Qwen2-VL

In parallelo alla classificazione dell'urgenza, l'immagine viene analizzata da Qwen2-VL-7B-Instruct. Il modello interpreta visivamente la lesione e genera una descrizione clinica testuale organizzata in cinque aspetti principali, relativi alla forma, ai bordi, al colore, alla texture e alla presenza di caratteristiche considerate sospette.

Questo passaggio trasforma quindi il contenuto visuale in una rappresentazione testuale strutturata. La descrizione prodotta non rappresenta ancora una decisione diagnostica,

ma viene utilizzata come query per la fase di ricerca dei casi clinici simili.

1.2.3. Stage 3 - Recupero di casi clinici simili

Il terzo stadio introduce un meccanismo di Retrieval-Augmented Generation basato su ChromaDB. La descrizione generata da Qwen2-VL viene convertita in una rappresentazione vettoriale mediante il modello `all-MiniLM-L6-v2` e confrontata con le descrizioni presenti nell'indice vettoriale.

La ricerca utilizza la similarità coseno e seleziona i cinque casi più vicini alla descrizione della lesione corrente. Per ciascun risultato vengono recuperate informazioni quali l'identificativo anonimizzato del paziente, la diagnosi associata, il livello di urgenza e il punteggio di similarità. In questo modo la pipeline affianca alla valutazione dell'immagine un riferimento a casi clinici precedenti con caratteristiche semanticamente simili.

1.2.4. Stage 4 - Sintesi clinica con BioMistral

Le informazioni prodotte nei primi tre stadi vengono successivamente aggregate e fornite a BioMistral-7B insieme ai dati relativi alla sintomatologia del paziente. Il modello riceve quindi la classificazione prodotta da EfficientNet-B4, la descrizione visuale generata da Qwen2-VL e i casi recuperati dal sistema RAG, disponendo di un contesto più ampio rispetto a quello disponibile nei singoli stadi precedenti.

BioMistral produce una risposta strutturata contenente il livello finale di urgenza, la relativa confidenza, una motivazione della decisione, l'azione raccomandata e una possibile patologia associata. Questo risultato rappresenta l'uscita della componente di inferenza vera e propria e viene successivamente elaborato dall'adaptation layer.

1.2.5. Adaptation layer e assegnazione della priorità

L'adaptation layer converte il livello di urgenza prodotto dalla pipeline nella scala P1-P4 utilizzata per il triage. La funzione `map_urgency_to_p_scale()` applica una serie di regole che tengono conto sia della classe di urgenza sia, per i casi `HIGH`, del livello di confidenza ottenuto.

Un risultato `HIGH` con confidenza superiore a 0.85 viene associato alla priorità P1, con un tempo previsto di presa in carico pari a 24 ore. Gli altri casi `HIGH` vengono assegnati a P2 con un intervallo di 48 ore, mentre le classi `MEDIUM` e `LOW` vengono convertite rispettivamente in P3, con 72 ore, e P4, con 7 giorni.

L'output finale comprende quindi la priorità P1-P4, il livello di confidenza, lo specialista indicato e il relativo SLA. L'adaptation layer separa in questo modo il risultato interno prodotto dai modelli dalla rappresentazione utilizzata per il triage clinico.

La Figura 1 riassume i principali componenti dell'architettura e il percorso seguito dalle informazioni durante l'elaborazione di una richiesta di triage.




Figura 1: Architettura logica di DermaTriage e flusso principale di elaborazione

1.3. Componenti persistenti, modelli e dipendenze esterne

Oltre ai componenti coinvolti direttamente nel flusso di inferenza, DermaTriage utilizza diverse risorse persistenti per conservare i dati necessari al funzionamento della pipeline, i modelli e le informazioni prodotte durante l'esecuzione. Una parte di queste risorse viene utilizzata durante l'elaborazione delle richieste, mentre altre supportano la gestione e l'aggiornamento del sistema.

1.3.1. Dataset e persistenza dei dati

Il dataset utilizzato dal sistema RAG è conservato localmente nel file `RAG_dataset.csv` e contiene 2298 casi clinici derivati dal dataset pubblico ISIC. Le informazioni necessarie al retrieval vengono indicizzate in ChromaDB, il cui database vettoriale è mantenuto in modo persistente all'interno dell'ambiente DermaTriage.

Oltre alle risorse utilizzate dal RAG, il sistema conserva localmente le diagnosi prodotte, le correzioni effettuate durante la revisione dei risultati, le versioni dei prompt e le informazioni relative alle versioni dei modelli. Questi dati vengono utilizzati dalle funzionalità amministrative e dai meccanismi di aggiornamento del sistema.

Le immagini provenienti dalle richieste B4 vengono elaborate durante il processo di triage

senza essere aggiunte in modo permanente al dataset utilizzato dal sistema RAG. Quelle impiegate per l'addestramento sono invece conservate insieme ai relativi metadati, mentre file distinti definiscono gli insiemi impiegati nelle fasi di training, validation e test.

1.3.2. Modelli e checkpoint

I pesi del classificatore EfficientNet-B4 sono memorizzati localmente e caricati dal relativo checkpoint per l'esecuzione dell'inferenza. Il sistema mantiene inoltre i checkpoint prodotti dai successivi cicli di retraining e una copia di backup, così da supportare il versionamento del classificatore e il ripristino di una versione precedente quando necessario.

Qwen2-VL-7B-Instruct, BioMistral-7B e `all-MiniLM-L6-v2` vengono invece acquisiti tramite Hugging Face e caricati nell'ambiente di esecuzione di DermaTriage. Una volta disponibili localmente, vengono utilizzati direttamente dalla pipeline senza richiedere un servizio remoto di inferenza durante l'elaborazione dei casi clinici.

1.3.3. Ambiente di esecuzione e servizi esterni

DermaTriage è predisposto per l'esecuzione su un ambiente Linux dotato di GPU NVIDIA e supporto CUDA. L'applicazione FastAPI viene eseguita tramite Uvicorn ed espone le funzionalità necessarie all'accesso alla pipeline e alle operazioni amministrative. L'esecuzione dei modelli può avvenire anche su CPU, con tempi di elaborazione maggiori rispetto all'utilizzo dell'accelerazione GPU.

La principale interazione con un sistema esterno durante il funzionamento operativo rimane quella con B4. Attraverso le relative API, DermaTriage recupera i dati e i documenti necessari all'elaborazione, restituisce gli output diagnostici e può acquisire gli esiti clinici validati utilizzati nei processi di aggiornamento.

1.4. Aggiornamento e validazione del sistema

DermaTriage utilizza le correzioni raccolte durante la revisione dei risultati per aggiornare nel tempo alcuni componenti della pipeline. Il processo interessa sia i prompt utilizzati dai modelli generativi sia il classificatore EfficientNet-B4, attraverso due meccanismi distinti. Nel primo caso vengono aggiornati i prompt utilizzati dai modelli, mentre nel secondo vengono aggiornati i pesi del classificatore mediante un nuovo ciclo di fine-tuning.

1.4.1. Validazione clinica e raccolta del feedback

Le diagnosi prodotte da DermaTriage possono essere sottoposte a revisione da parte del personale medico. La validazione consente di confermare l'esito proposto dal sistema oppure di registrare una correzione, mantenuta come feedback associato alla diagnosi.

Gli esiti validati possono essere recuperati anche attraverso l'integrazione con B4. Le correzioni registrate alimentano due meccanismi distinti: l'evoluzione dei prompt utilizza

gli esempi corretti più recenti, mentre le discordanze tra l'esito del sistema e la valutazione medica vengono raccolte per il successivo retraining di EfficientNet-B4. I due meccanismi sono descritti rispettivamente nelle Sezioni 1.4.2 e 1.4.3.

1.4.2. Evoluzione dei prompt

L'aggiornamento dei prompt è gestito dal componente **PromptManager**. Il sistema tiene traccia delle correzioni effettuate durante la revisione delle diagnosi. L'aggiornamento viene attivato ogni dieci correzioni e utilizza una finestra scorrevole composta dai venti esempi più recenti.

Le diverse versioni vengono mantenute in modo persistente, permettendo di distinguere il prompt attualmente utilizzato da quelli prodotti in precedenza. Il meccanismo riguarda i prompt associati a Qwen2-VL e BioMistral e consente di modificarne le istruzioni mantenendo invariati i rispettivi parametri.

1.4.3. Retraining del classificatore EfficientNet-B4

Il retraining di EfficientNet-B4 viene attivato al raggiungimento di 50 correzioni associate a casi in cui l'esito prodotto dal sistema risulta discordante rispetto alla valutazione del personale medico. Il controllo viene eseguito tramite un trigger event-driven e il ciclo può essere avviato anche manualmente attraverso le funzionalità amministrative dedicate.

Per costruire i dati necessari al nuovo ciclo di addestramento, DermaTriage recupera tramite B4 i consulti e le relative immagini. Ai fini del retraining vengono utilizzati file JPEG e PNG, mentre i documenti PDF sono esclusi. Le priorità cliniche validate vengono ricondotte alle classi del classificatore secondo la corrispondenza P1/P2-HIGH, P3-MEDIUM e P4-LOW.

Il fine-tuning interessa gli ultimi due blocchi di feature extraction e la testa di classificazione di EfficientNet-B4. Ogni ciclo prevede 10 epoche, con learning rate pari a 5×10^{-6} per il backbone e 3×10^{-5} per il classificatore. I pesi di classe [3.0, 2.0, 1.0] assegnano maggiore importanza alla classe HIGH durante l'aggiornamento.

1.4.4. Validazione tecnica e gestione delle versioni

Prima che una nuova versione del classificatore sostituisca quella in uso, le sue prestazioni vengono confrontate con i valori di riferimento del modello precedente. La validazione considera in particolare la sensibilità sulla classe HIGH, la frequenza dei casi urgenti classificati erroneamente come LOW e l'accuratezza complessiva.

L'aggiornamento non deve peggiorare la sensibilità sui casi HIGH né aumentare i falsi LOW; inoltre, l'accuratezza complessiva non può diminuire di oltre cinque punti percentuali rispetto al riferimento. Come baseline vengono utilizzati una sensibilità HIGH del 90.24%, un tasso di falsi LOW del 7.93% e un'accuratezza complessiva dell'81.74%.

I checkpoint prodotti dai cicli di retraining vengono conservati come versioni distinte del classificatore. È inoltre previsto un checkpoint di backup della versione attiva, utilizzabile per ripristinare il modello precedente. Il rollback automatico è previsto nel caso in cui l'accuratezza della nuova versione diminuisca di oltre il 5% rispetto al modello attivo.

Le informazioni sulle diverse versioni e sulla cronologia dei cicli di retraining vengono mantenute in modo persistente, permettendo di ricostruire gli aggiornamenti effettuati nel tempo.

2. Identificazione degli asset

DermaTriage comprende diversi asset che concorrono al processo di triage e al mantenimento della pipeline nel tempo. Oltre ai dati clinici acquisiti per ciascun caso, rientrano tra gli asset le informazioni prodotte durante l'inferenza, i dataset e le strutture di persistenza, i modelli AI e gli artefatti utilizzati nei processi di aggiornamento e validazione.

Le dipendenze tra questi elementi consentono agli effetti di un eventuale malfunzionamento di propagarsi tra differenti stadi della pipeline. Gli asset comprendono quindi sia le risorse direttamente coinvolte nella determinazione della priorità clinica, sia quelle necessarie al recupero delle informazioni e all'evoluzione del sistema.

2.1. Dati clinici e input

Il processo di triage riceve come input l'immagine della lesione e le informazioni cliniche associate al paziente, tra cui età, sesso, localizzazione anatomica e sintomatologia disponibile. Nel flusso integrato con B4, ogni richiesta è inoltre associata a un consulto specifico, il cui identificativo consente di mantenere il corretto collegamento tra i dati acquisiti, l'elaborazione effettuata e il risultato prodotto da DermaTriage.

ID	Asset	Tipo	Funzione / utilizzo	Input / output	Fase
A01	Immagine dermatologica	Dato clinico grezzo	Fornisce l'informazione visiva della lesione utilizzata per la classificazione dell'urgenza e la generazione della descrizione clinica.	Input: immagine della lesione acquisita tramite B4 o <code>/analyze</code> . Output: fornita a EfficientNet-B4 e Qwen2-VL.	Acquisizione e inferenza
A02	Dati clinici, demografici e sintomatologia	Dato clinico strutturato	Fornisce il contesto clinico e demografico complementare all'immagine e contribuisce alla successiva elaborazione del caso.	Input: età, sesso, localizzazione anatomica e sintomatologia disponibile. Output: informazioni contestuali utilizzate nella pipeline; i sintomi alimentano la sintesi clinica di BioMistral.	Acquisizione e inferenza
A03	Identificativo del consulto	Metadato applicativo	Identifica la richiesta B4 e mantiene l'associazione tra il consulto, i dati elaborati e il relativo risultato.	Input: <code>consulto_id</code> ricevuto tramite <code>/diagnose</code> . Output: riferimento utilizzato per recuperare il caso e associare il risultato alla richiesta corrispondente.	Integrazione e gestione del caso

Tabella 1: Asset relativi ai dati clinici e agli input di DermaTriage.

2.2. Inferenze e risultati della pipeline

Durante l’inferenza, i diversi stadi della pipeline producono informazioni intermedie che vengono progressivamente combinate fino alla determinazione della priorità clinica finale. Tali risultati comprendono la classificazione iniziale dell’urgenza, la descrizione clinica della lesione, i casi simili recuperati dal sistema RAG e la successiva sintesi clinica.

ID	Asset	Tipo	Funzione / utilizzo	Input / output	Fase
A04	Classificazione di urgenza EfficientNet-B4	Inferenza del modello	Fornisce una prima valutazione dell’urgenza della lesione, utilizzata dagli stadi successivi della pipeline.	Input: immagine dermatologica. Output: classe HIGH, MEDIUM o LOW, confidence e probabilità associate.	Inferenza - Stage 1
A05	Descrizione clinica Qwen2-VL	Inferenza del modello	Produce una descrizione strutturata delle caratteristiche visibili della lesione, utilizzata per contestualizzare il caso.	Input: immagine dermatologica. Output: descrizione di forma, bordi, colore, texture e caratteristiche sospette della lesione.	Inferenza - Stage 2
A06	Casi clinici simili recuperati dal RAG	Informazione recuperata	Fornisce precedenti clinici semanticamente simili al caso corrente come supporto alla successiva sintesi clinica.	Input: descrizione clinica della lesione. Output: cinque casi simili con diagnosi, urgenza, similarità e relativo identificativo anonimizzato.	Inferenza - Stage 3
A07	Sintesi clinica BioMistral	Inferenza del modello	Integra i risultati degli stadi precedenti e la sintomatologia disponibile per formulare una valutazione clinica complessiva.	Input: risultati degli Stage 1-3 e sintomi. Output: urgenza finale, confidence, reasoning, azione raccomandata e patologia prevista.	Inferenza - Stage 4
A08	Risultato finale di triage	Output clinico	Esprime la priorità clinica restituita dal sistema e costituisce il risultato conclusivo del processo di triage.	Input: sintesi clinica e logica dell’Adaptation Layer. Output: priorità P1-P4 e informazioni associate al risultato.	Decisione finale

Tabella 2: Asset relativi alle inferenze e ai risultati prodotti dalla pipeline di DermaTriage.

2.3. Dataset e persistenza

DermaTriage utilizza diverse risorse persistenti per supportare il recupero dei casi clinici, l’addestramento e la valutazione del classificatore e la conservazione dei risultati prodotti

durante l'esecuzione. Questi asset comprendono sia dati strutturati sia rappresentazioni indicizzate utilizzate direttamente dalla pipeline.

ID	Asset	Tipo	Funzione / utilizzo	Input / output	Fase
A09	Dataset clinico RAG	Dataset clinico	Conserva i casi clinici utilizzati come base informativa per il retrieval dei casi simili e come base per la preparazione dei dati del classificatore.	Input: casi clinici strutturati con descrizione clinica, diagnosi, livello di urgenza e relativi metadati. Output: base informativa utilizzata per la costruzione dell'indice vettoriale ChromaDB e per la preparazione dei dati del classificatore.	Persistenza e preparazione dati
A10	Indice vettoriale ChromaDB	Indice vettoriale	Memorizza e indicizza le rappresentazioni vettoriali delle descrizioni cliniche, consentendo la ricerca per similarità semantica.	Input: embedding delle descrizioni cliniche indicizzate e embedding della query. Output: riferimenti ai cinque casi più simili e relativi valori di similarità, utilizzati dal sistema RAG per costruire il risultato del retrieval.	Persistenza e inferenza - Stage 3
A11	Dati di training, validation e test	Dataset ML	Supporta l'addestramento, la selezione del modello e la valutazione delle prestazioni di EfficientNet-B4.	Input: immagini, metadati e dati derivati dalla preparazione del dataset. Output: split distinti per training, validation e test utilizzati nel ciclo di sviluppo del modello.	Training e validazione
A12	Storico delle diagnosi	Dato persistente	Conserva localmente i risultati diagnostici prodotti da DermaTriage e ne supporta la consultazione e la gestione successiva.	Input: risultati prodotti dalle richieste di triage. Output: diagnosi archiviate e disponibili per la consultazione e per eventuali revisioni successive.	Persistenza dei risultati

Tabella 3: Asset relativi ai dataset e alle risorse persistenti di DermaTriage.

2.4. Feedback e aggiornamento

Il mantenimento della pipeline utilizza gli esiti della validazione clinica per aggiornare nel tempo alcuni dei suoi componenti. Le conferme e le correzioni effettuate dal personale

medico alimentano l'evoluzione dei prompt e, in caso di discordanza con il risultato prodotto dal sistema, il retraining di EfficientNet-B4. Le nuove versioni del classificatore sono inoltre sottoposte a criteri di validazione prima della loro adozione.

ID	Asset	Tipo	Funzione / utilizzo	Input / output	Fase
A13	Feedback clinico validato	Dato clinico validato	Raccoglie le conferme e le correzioni effettuate dal personale medico e fornisce il riferimento clinico utilizzato nei processi di aggiornamento del sistema.	Input: esito prodotto da DermaTriage e successiva validazione medica. Output: conferme o correzioni utilizzate per l'evoluzione dei prompt e, nei casi discordanti, per il retraining di EfficientNet-B4.	Validazione e aggiornamento
A14	Prompt e storico delle versioni	Artefatto AI	Contiene le istruzioni utilizzate da Qwen2-VL e BioMistral e conserva le relative versioni generate dal processo di evoluzione dei prompt.	Input: correzioni cliniche recenti utilizzate per aggiornare i prompt. Output: prompt aggiornati utilizzati dai modelli generativi durante l'inferenza.	Aggiornamento e inferenza
A15	Metriche e criteri di accettazione del modello	Artefatto di validazione	Definisce i riferimenti utilizzati per confrontare una nuova versione di EfficientNet-B4 con il modello attualmente in uso prima della sua adozione.	Input: prestazioni della nuova versione e valori di riferimento del modello attivo. Output: valutazione basata su sensibilità HIGH, falsi LOW e accuratezza complessiva, utilizzata nella decisione di adozione o rollback.	Validazione del modello

Tabella 4: Asset relativi al feedback clinico e ai processi di aggiornamento di DermaTriage.

2.5. Modelli e artefatti AI

La pipeline di DermaTriage utilizza più modelli con funzioni distinte e complementari. EfficientNet-B4 effettua la classificazione iniziale dell'urgenza, Qwen2-VL produce la descrizione clinica della lesione, BioMistral integra le informazioni disponibili nella sintesi clinica e all-MiniLM-L6-v2 genera le rappresentazioni vettoriali utilizzate dal sistema RAG. Al classificatore EfficientNet-B4 è inoltre associato il checkpoint contenente i parametri appresi utilizzati durante l'esecuzione.

ID	Asset	Tipo	Funzione / utilizzo	Input / output	Fase
A16	Modello EfficientNet-B4	Modello di classificazione	Analizza l'immagine dermatologica e fornisce la prima classificazione dell'urgenza utilizzata dagli stadi successivi della pipeline. Il suo comportamento è determinato dai parametri appresi durante l'addestramento e caricati dal checkpoint attivo.	Input: immagine dermatologica e parametri del modello caricati dal checkpoint. Output: classe HIGH, MEDIUM o LOW, confidence e probabilità associate.	Training e inferenza - Stage 1
A17	Modello Qwen2-VL	Modello multimodale	Analizza visivamente la lesione e genera una descrizione clinica strutturata utilizzata negli stadi successivi della pipeline.	Input: immagine dermatologica e prompt. Output: descrizione di forma, bordi, colore, texture e caratteristiche sospette della lesione.	Inferenza - Stage 2
A18	Modello BioMistral	Modello linguistico	Integra le informazioni prodotte dagli stadi precedenti e la sintomatologia disponibile per generare la sintesi clinica complessiva del caso.	Input: classificazione di urgenza, descrizione clinica, casi simili, sintomi e prompt. Output: urgenza finale, confidence, reasoning, azione raccomandata e patologia prevista.	Inferenza - Stage 4
A19	Modello all-MiniLM-L6-v2	Modello di embedding	Genera le rappresentazioni vettoriali delle descrizioni cliniche utilizzate per confrontare semanticamente il caso corrente con i casi indicizzati in ChromaDB.	Input: descrizione clinica testuale. Output: embedding utilizzato per la ricerca dei casi semanticamente simili.	Retrieval - Stage 3

Tabella 5: Asset relativi ai modelli e agli artefatti AI di DermaTriage.

2.6. Logica decisionale

Al termine della pipeline di inferenza, il risultato prodotto da BioMistral viene trasformato nella scala di priorità clinica utilizzata da DermaTriage. Questa conversione è regolata dall'Adaptation Layer, che applica criteri deterministici al livello di urgenza e alla relativa confidenza per assegnare la priorità finale da P1 a P4.

ID	Asset	Tipo	Funzione / utilizzo	Input / output	Fase
A20	Regole dell'Adaptation Layer	Logica decisionale	Converte il livello di urgenza prodotto dalla pipeline nella priorità clinica P1-P4 applicando le regole previste per il triage.	Input: livello di urgenza e relativa confidenza. Output: priorità P1-P4, specialista indicato e relativo SLA.	Decisione finale

Tabella 6: Asset relativo alla logica decisionale finale di DermaTriage.

2.7. Servizi applicativi e configurazione

L'esecuzione della pipeline di DermaTriage dipende anche dai servizi che gestiscono l'interazione con l'esterno e l'accesso alle funzionalità del sistema. La piattaforma B4 supporta lo scambio delle informazioni relative ai consulti, mentre il servizio applicativo FastAPI espone le funzionalità di DermaTriage. A questi componenti si affianca la configurazione operativa, che definisce i parametri e le credenziali necessari al loro funzionamento.

ID	Asset	Tipo	Funzione / utilizzo	Input / output	Fase
A21	Piattaforma B4	Servizio esterno	Gestisce l'interazione con il paziente e rende disponibili a DermaTriage le informazioni associate ai consulti, supportando inoltre la restituzione e la successiva validazione dei risultati.	Input: dati e documenti associati al consulto e risultati prodotti da DermaTriage. Output: informazioni del consulto, immagini e risultati validati accessibili a DermaTriage tramite API.	Acquisizione, integrazione e aggiornamento
A22	Servizio applicativo FastAPI	Servizio applicativo	Esponde le funzionalità di DermaTriage e gestisce le richieste necessarie all'accesso alla pipeline di inferenza e alle altre operazioni applicative.	Input: richieste ricevute attraverso gli endpoint applicativi. Output: attivazione delle operazioni richieste e restituzione dei relativi risultati.	Esecuzione e integrazione
A23	Configurazione operativa e credenziali	Artefatto di configurazione	Definisce i parametri necessari al caricamento delle risorse, all'esecuzione della pipeline e all'autenticazione verso i servizi protetti e la piattaforma B4.	Input: variabili d'ambiente relative a percorsi, modelli, parametri operativi e credenziali. Output: configurazione utilizzata dai componenti di DermaTriage durante esecuzione, integrazione e retraining.	Configurazione ed esecuzione

Tabella 7: Asset relativi ai servizi applicativi e alla configurazione di DermaTriage.

3. Failure Mode and Effects Analysis

La Failure Mode and Effects Analysis (FMEA) è una metodologia utilizzata per identificare le possibili modalità di guasto di un sistema e valutarne le conseguenze. L'analisi considera gli asset selezionati tra quelli individuati nell'Asset Model, concentrandosi sugli elementi maggiormente significativi per il funzionamento della pipeline di DermaTriage. Per ciascun asset vengono esaminate le funzioni svolte, i relativi prerequisiti e i possibili failure mode, individuandone le cause e gli effetti che possono propagarsi agli altri componenti del sistema.

3.1. A01 – Immagine dermatologica

L'asset A01 rappresenta l'immagine della lesione dermatologica acquisita per il caso clinico e utilizzata come principale informazione visiva della pipeline. L'immagine può essere recuperata nell'ambito del consulto gestito tramite B4 oppure fornita direttamente attraverso l'endpoint `/analyze`.

All'interno della pipeline, l'immagine viene utilizzata nello Stage 1 da EfficientNet-B4 per la classificazione iniziale dell'urgenza e nello Stage 2 da Qwen2-VL per la generazione della descrizione clinica della lesione. La correttezza e l'adeguatezza dell'immagine costituiscono quindi un prerequisito per le successive elaborazioni basate sull'informazione visiva.

3.1.1. Funzioni e prerequisiti

Le principali funzioni dell'asset e i prerequisiti necessari al loro svolgimento sono riportati nella Tabella 8.

ID	Funzione	Prerequisiti
F01.1	Rappresentazione visiva della lesione	Acquisizione di un'immagine che rappresenti in modo adeguato la lesione dermatologica oggetto del consulto.
F01.2	Associazione dell'immagine al caso clinico	Corretta corrispondenza tra l'immagine acquisita e il consulto o la richiesta di analisi a cui essa appartiene.
F01.3	Fornitura dell'input visivo alla pipeline di inferenza	Disponibilità dell'immagine in un formato utilizzabile e corretta trasmissione dell'input a EfficientNet-B4 nello Stage 1 e a Qwen2-VL nello Stage 2.

Tabella 8: Funzioni e prerequisiti dell'asset A01 – Immagine dermatologica.

3.1.2. Failure mode

Sulla base delle funzioni individuate vengono considerate le principali modalità con cui l'asset A01 può non svolgere correttamente il proprio compito, ovvero i failure mode.

ID	Failure mode	Possibili cause	Effetti
FM01.1	Immagine di qualità insufficiente	Sfocatura, illuminazione inadeguata, risoluzione insufficiente, presenza di artefatti oppure condizioni di acquisizione che rendono poco distinguibili le caratteristiche della lesione.	L'immagine non rappresenta con sufficiente chiarezza le caratteristiche visive della lesione, riducendo l'affidabilità delle elaborazioni effettuate da EfficientNet-B4 e Qwen2-VL.
FM01.2	Lesione rappresentata in modo incompleto o non adeguato	Inquadratura parziale, porzione rilevante della lesione esclusa dall'immagine oppure acquisizione di una regione cutanea che non consente di osservare adeguatamente la lesione di interesse.	I modelli ricevono una rappresentazione visiva incompleta del caso e possono quindi produrre una classificazione dell'urgenza o una descrizione clinica non rappresentative della lesione effettiva.
FM01.3	Immagine associata al caso clinico errato	Errata associazione tra immagine e consulto, selezione del documento non corrispondente al caso oppure errore nella gestione del riferimento utilizzato per recuperare l'immagine.	La pipeline elabora un'immagine appartenente a un caso differente rispetto alle informazioni cliniche associate alla richiesta. Le inferenze prodotte risultano quindi riferite a dati non coerenti tra loro e possono determinare un risultato di triage non pertinente al paziente analizzato.
FM01.4	Immagine non disponibile o non utilizzabile dalla pipeline	Formato non supportato, file danneggiato, errore nella lettura del file, mancato recupero dell'immagine dal servizio di origine oppure errore durante il trasferimento.	EfficientNet-B4 e Qwen2-VL non dispongono di un input visivo utilizzabile e non possono quindi completare normalmente le rispettive elaborazioni.

Tabella 9: Failure mode individuati per l'asset A01 – Immagine dermatologica.

3.2. A09 – Dataset clinico RAG

L'asset A09 rappresenta il dataset clinico utilizzato dal sistema RAG, memorizzato nel file `RAG_dataset.csv`. Il dataset contiene casi clinici dermatologici caratterizzati da informazioni demografiche, localizzazione della lesione, descrizione clinica, diagnosi e livello di urgenza.

Durante l'inferenza, le descrizioni cliniche contenute nel dataset costituiscono la base informativa utilizzata nello Stage 3 per il recupero dei casi clinici più simili alla descrizione prodotta da Qwen2-VL. Il dataset rappresenta inoltre la base da cui vengono derivati i dati utilizzati per l'addestramento del classificatore EfficientNet-B4.

3.2.1. Funzioni e prerequisiti

Le principali funzioni dell'asset e i prerequisiti necessari al loro svolgimento sono riportati nella Tabella 10.

ID	Funzione	Prerequisiti
F09.1	Rappresentazione dei casi clinici dermatologici	Presenza di record clinici correttamente strutturati e contenenti informazioni coerenti relative a descrizione della lesione, diagnosi e livello di urgenza.
F09.2	Fornitura della base informativa per il retrieval RAG	Disponibilità delle descrizioni cliniche necessarie all'indicizzazione e corretta associazione tra descrizione, diagnosi, urgenza e relativo caso clinico.
F09.3	Supporto alla costruzione dei dati per l'addestramento	Disponibilità di record e label utilizzabili per derivare i dataset impiegati nel processo di training del classificatore.

Tabella 10: Funzioni e prerequisiti dell'asset A09 – Dataset clinico RAG.

3.2.2. Failure mode

Sulla base delle funzioni individuate vengono considerate le principali modalità con cui l'asset A09 può non svolgere correttamente il proprio compito, ovvero i failure mode.

ID	Failure mode	Possibili cause	Effetti
FM09.1	Record clinici incompleti o incoerenti	Valori mancanti, informazioni cliniche non coerenti tra loro, errori nella compilazione dei record oppure associazione errata tra attributi appartenenti allo stesso caso.	Il dataset rappresenta in modo incompleto o non corretto i casi clinici e può fornire informazioni non affidabili sia al sistema RAG sia ai processi che utilizzano il dataset come base per la preparazione dei dati di addestramento.
FM09.2	Associazione errata tra descrizione clinica e diagnosi o urgenza	Label diagnostica o livello di urgenza non corrispondenti alla descrizione clinica del caso oppure errore nell'associazione dei campi appartenenti allo stesso record.	Un caso clinico può essere recuperato come riferimento insieme a una diagnosi o a un livello di urgenza non corretti. L'errore può propagarsi allo Stage 3 e influenzare il contesto fornito a BioMistral, oppure essere trasferito ai dati utilizzati nell'addestramento del classificatore.
FM09.3	Dataset non sufficientemente rappresentativo del dominio	Distribuzione sbilanciata dei casi, sottorappresentazione di determinate tipologie di lesione o caratteristiche della popolazione non adeguatamente coperte dal dataset.	Il sistema dispone di una base clinica meno rappresentativa rispetto ai casi incontrati in esercizio. Il retrieval può individuare riferimenti poco pertinenti per alcuni casi e i dati derivati dal dataset possono contribuire a una capacità di generalizzazione insufficiente del classificatore.
FM09.4	Dataset non disponibile o non correttamente accessibile	File mancante o danneggiato, percorso configurato in modo errato, errore durante la lettura oppure indisponibilità della risorsa nel momento in cui deve essere utilizzata.	Il sistema non dispone della base informativa necessaria per costruire o aggiornare il supporto al retrieval RAG e i processi che dipendono dal dataset non possono svolgersi secondo il normale funzionamento previsto.

Tabella 11: Failure mode individuati per l'asset A09 – Dataset clinico RAG.

3.3. A16 – Modello EfficientNet-B4

L'asset A16 riguarda il modello EfficientNet-B4 utilizzato per la classificazione iniziale dell'urgenza dermatologica e i parametri appresi durante l'addestramento, caricati dal checkpoint attivo. A partire dall'immagine della lesione, il modello produce una classe di urgenza tra HIGH, MEDIUM e LOW, insieme alla confidence della classificazione e alle probabilità associate alle diverse classi.

Il risultato dello Stage 1 viene utilizzato dalle successive elaborazioni della pipeline e contribuisce alla sintesi clinica prodotta da BioMistral e alla successiva determinazione della priorità P1–P4.

3.3.1. Funzioni e prerequisiti

Le principali funzioni dell'asset e i prerequisiti necessari al loro svolgimento sono riportati nella Tabella 12.

ID	Funzione	Prerequisiti
F16.1	Estrazione delle caratteristiche visive	Disponibilità di un'immagine dermatologica acquisita correttamente (A01) e caricamento del modello con i relativi parametri.
F16.2	Classificazione dell'urgenza in HIGH, MEDIUM o LOW	Corretta elaborazione dell'immagine e utilizzo dei parametri previsti per la versione attiva del classificatore.
F16.3	Produzione della confidence e delle probabilità associate	Completamento corretto dell'inferenza e disponibilità dell'output numerico prodotto dal classificatore.
F16.4	Utilizzo della versione prevista del modello	Disponibilità del checkpoint attivo e corretta configurazione dei riferimenti utilizzati per il caricamento del modello (A23).

Tabella 12: Funzioni e prerequisiti dell'asset A16 – Modello EfficientNet-B4 e relativi pesi.

3.3.2. Failure mode

Sulla base delle funzioni individuate vengono considerate le principali modalità con cui l'asset A16 può non svolgere correttamente il proprio compito, ovvero i failure mode.

ID	Failure mode	Possibili cause	Effetti
FM16.1	Estrazione inadeguata delle caratteristiche visive	Qualità insufficiente dell'immagine, presenza di artefatti visivi oppure inquadratura non adeguata della lesione.	Le caratteristiche ricavate dall'immagine non rappresentano adeguatamente la lesione osservata, compromettendo l'informazione utilizzata dal classificatore per determinare la classe di urgenza.
FM16.2	Classificazione errata dell'urgenza	Limiti di generalizzazione del modello, distribuzione dei casi operativi differente da quella osservata durante l'addestramento oppure insufficiente capacità discriminativa tra le classi di urgenza.	Il modello assegna una classe HIGH, MEDIUM o LOW non coerente con l'effettiva urgenza del caso. L'errore può determinare una sovrastima o una sottostima dell'urgenza che si propaga agli stadi successivi, contribuendo così ad una valutazione finale del triage non appropriata.
FM16.3	Confidence o probabilità non coerenti con la classificazione	Calibrazione non adeguata delle probabilità prodotte dal modello oppure comportamento eccessivamente confidente su campioni incerti o poco rappresentativi.	La classe restituita è accompagnata da valori che non riflettono correttamente l'incertezza dell'inferenza. Gli stadi successivi ricevono quindi una valutazione non attendibile della confidenza associata alla classificazione.
FM16.4	Utilizzo di pesi o checkpoint non validi o non previsti	Corruzione o incompletezza del checkpoint, incompatibilità tra modello e parametri caricati, selezione di un checkpoint errato oppure mancato allineamento tra la versione validata e quella effettivamente utilizzata durante l'inferenza.	Il classificatore può operare con un comportamento diverso da quello previsto o validato, producendo classificazioni non affidabili. Nei casi in cui i parametri risultino incompatibili o non caricabili, l'inferenza può inoltre non essere completata.
FM16.5	Output di inferenza incompleto o non disponibile	Errore durante l'esecuzione del modello, incompatibilità tra input, modello e parametri caricati oppure anomalia software che interrompe l'elaborazione prima del suo completamento.	Lo Stage 1 non restituisce tutti gli elementi previsti, quali classe, confidence e probabilità, oppure non produce alcun risultato utilizzabile. Gli stadi dipendenti dall'output del classificatore non dispongono quindi delle informazioni necessarie per proseguire secondo il normale flusso della pipeline.

Tabella 13: Failure mode individuati per l'asset A16 – Modello EfficientNet-B4 e relativi pesi.